

Informe Final: Análisis Exploratorio del Titanic

Curso: Programación II — Ciencia de Datos

Universidad: Externado de Colombia

Integrantes

Juan Jacobo Beltrán — Líder de Datos y Líder de Repositorio

Helen Rueda — Líder de Reporte

1. Objetivo General

El presente informe documenta el desarrollo de un análisis exploratorio de datos aplicado al dataset del Titanic, obtenido de la plataforma Kaggle. El objetivo principal fue utilizar Python y la librería Pandas para explorar, limpiar, transformar y analizar los datos de los pasajeros del Titanic, respondiendo preguntas concretas sobre sus características demográficas y sus probabilidades de supervivencia.

El proyecto tuvo dos dimensiones principales. La primera fue técnica: aplicar herramientas de ciencia de datos para extraer información útil de un dataset real con datos faltantes, variables categóricas y numéricas, y múltiples dimensiones de análisis. La segunda fue colaborativa: desarrollar el proyecto usando GitHub como plataforma de control de versiones, practicando el flujo de trabajo profesional con ramas, commits, Pull Requests y resolución de conflictos.

2. Principales Hallazgos

2.1 Descripción del dataset

El dataset del Titanic está dividido en dos conjuntos: train.csv con 891 pasajeros e información de supervivencia, y test.csv con 418 pasajeros sin información de supervivencia. Al unirlos verticalmente se obtuvo un dataset combinado de 1309 pasajeros con 13 variables.

Las variables disponibles incluyen información demográfica como edad, sexo y clase del ticket; información familiar como número de hermanos, cónyuges, padres e hijos a bordo; información económica como la tarifa pagada y el número de cabina; e información logística como el puerto de embarque y el identificador del pasajero.

2.2 Datos faltantes

El análisis de datos faltantes reveló que la variable Cabin tiene el mayor porcentaje de valores faltantes con un 77.46%, lo que la hace poco útil para el análisis. La variable Age tiene un 20.09% de valores faltantes, lo que se tuvo en cuenta al calcular estadísticas de edad. La variable Embarked tiene solo 2 valores faltantes y Fare tiene 1, ambos sin mayor impacto en el análisis. La variable Survived tiene 418 valores faltantes que corresponden exactamente a los pasajeros del dataset test, lo cual es esperado.

2.3 Perfil general de los pasajeros

La edad promedio de los pasajeros era de 29.88 años con una mediana de 28 años, lo que indica una distribución relativamente simétrica. El pasajero más joven tenía 0.17 años y el más viejo tenía 80 años. La mayoría de los pasajeros embarcó en Southampton con un 69.93%, seguido de Cherbourg con 20.66% y Queenstown con 9.41%. La tarifa promedio general fue de \$33.30, con grandes diferencias entre clases.

2.4 Supervivencia general

De los 891 pasajeros del dataset train, 342 sobrevivieron representando el 38.38% del total, mientras que 549 murieron representando el 61.62%. La tasa de mortalidad fue significativamente alta, lo que refleja las condiciones extremas del desastre y la insuficiencia de botes salvavidas, que tenían capacidad para aproximadamente la mitad de los pasajeros a bordo.

2.5 Supervivencia por sexo

Las mujeres tuvieron una tasa de supervivencia del 74.20% comparado con el 18.89% de los hombres. Esta diferencia es la más marcada de todo el análisis y confirma que la política de evacuación del Titanic priorizaba mujeres y niños sobre los hombres adultos.

De cada 4 mujeres, aproximadamente 3 sobrevivieron. De cada 5 hombres, aproximadamente solo 1 sobrevivió.

2.6 Supervivencia por clase

Los pasajeros de primera clase tuvieron una tasa de supervivencia del 62.96%, los de segunda clase del 47.28% y los de tercera clase del 24.24%.

La diferencia entre primera y tercera clase es muy marcada, lo que refleja las desigualdades sociales de la época. Los pasajeros de primera clase tenían cabinas en las cubiertas superiores con acceso más fácil a los botes salvavidas, mientras que los de tercera clase estaban en las cubiertas inferiores con mayor dificultad para evacuar.

2.7 Supervivencia por puerto de embarque

Los pasajeros embarcados en Cherbourg tuvieron la mayor tasa de supervivencia con un 55.36%, seguidos de Queenstown con 38.96% y Southampton con 33.70%.

La mayor tasa de supervivencia de Cherbourg se explica porque ese puerto tenía una mayor proporción de pasajeros de primera clase, lo que indirectamente favoreció su supervivencia.

2.8 Supervivencia por edad

Los niños menores de 18 años tuvieron una tasa de supervivencia mayor que los hombres adultos de 18 años o más. Esto es consistente con la política de evacuación que priorizaba niños.

Los pasajeros en edades extremas, menores de 10 o mayores de 50 años, tuvieron tasas de supervivencia diferentes al resto, siendo los niños los más beneficiados por la política de evacuación.

2.9 Supervivencia por grupos familiares

Se creó la variable Familiares como la suma de SibSp y Parch para representar el número total de familiares a bordo.

Los pasajeros se clasificaron en tres grupos:

Sin familiares: 537 pasajeros en train

Familias pequeñas: de 1 a 3 familiares

Familias grandes: con 4 o más familiares

Los pasajeros con familias pequeñas tuvieron una tasa de supervivencia ligeramente mayor que los que viajaban solos o con familias grandes. Las familias grandes tuvieron la menor tasa de supervivencia, posiblemente porque era más difícil coordinar la evacuación de un grupo numeroso.

2.10 Tarifas por clase

La tarifa promedio de primera clase fue de \$87.51, la de segunda clase fue de \$21.18 y la de tercera clase fue de \$13.30.

La tarifa de primera clase fue 6.6 veces más cara que la de tercera clase, lo que refleja las grandes diferencias económicas entre los grupos de pasajeros a bordo del Titanic.

3. Conclusiones Finales

A partir del análisis exploratorio realizado se puede concluir que la supervivencia en el Titanic no fue aleatoria sino que estuvo fuertemente determinada por factores sociales, demográficos y económicos.

El factor más determinante fue el sexo, con las mujeres teniendo una probabilidad de supervivencia casi 4 veces mayor que los hombres. El segundo factor más importante fue la clase del ticket, que determinaba la ubicación en el barco y el acceso a los botes salvavidas. La edad también jugó un papel importante, con los niños teniendo mayor probabilidad de ser evacuados. El puerto de embarque fue un factor indirecto, ya que estaba correlacionado con la clase del ticket.

El perfil del pasajero con más probabilidades de sobrevivir era una mujer joven de primera clase, embarcada en Cherbourg, viajando con una familia pequeña y con cabina asignada. Por el contrario, el perfil con menos probabilidades de sobrevivir era un hombre adulto de tercera clase que viajaba solo, embarcado en Southampton o Queenstown y sin cabina asignada.

Estos resultados reflejan las profundas desigualdades sociales de la época y cómo estas influyeron directamente en las probabilidades de supervivencia durante el naufragio del Titanic el 15 de abril de 1912, uno de los desastres marítimos más importantes de la historia.

4. Proceso Colaborativo y Conflicto Resuelto

4.1 Distribución del trabajo

El proyecto se desarrolló de forma colaborativa entre dos integrantes usando GitHub Desktop como herramienta principal de control de versiones.

La distribución del trabajo fue la siguiente:

Jacobo

Se encargó de los pasos 1 al 5 que incluyen la carga de datos, descripción de variables, estadísticas básicas, creación de la variable Familiares y unión vertical de los datasets. También realizó las preguntas 8b, 8d, 9b, 9d y 10, los gráficos de supervivencia por clase y por puerto, y la creación del archivo requirements.txt.

Helen

Se encargó de los pasos 6 y 7 que incluyen la revisión de estadísticas del dataset combinado y el análisis de variables faltantes. También realizó las preguntas 8a, 8c, 8e, 8f y 8g; las preguntas 9a, 9c y 9e; el punto 11 de proporción por sexo, grupo etario y cabina; los gráficos de edad, sexo, familia y tarifas; la exportación de tablas CSV; y la conclusión final del punto 13.

4.2 Ramas utilizadas

Se crearon dos ramas de trabajo además de main:

rama/analisis-estadistico-inicial: rama principal de Jacobo donde se desarrollaron los pasos iniciales del análisis.

rama/unificacion-datos: rama principal de Helen donde se desarrollaron los pasos de análisis profundo, visualizaciones y conclusiones.

4.3 Commits realizados

El proyecto cuenta con 27 commits distribuidos entre los dos integrantes, con 15 commits de Jacobo y 12 commits de Helen, evidenciando una participación equilibrada en el desarrollo del proyecto.

4.4 Pull Requests realizados

Se realizaron un total de 6 Pull Requests fusionados en main:

PR1: Análisis estadístico inicial pasos 1 al 5 — Jacobo

PR2: Análisis datos combinados pasos 6, 7, 8a, 8c, 8e, 8f y 8g — Helen

PR3: Análisis estadístico pasos 8b, 8d, 9b, 9d, 10, 12 y requirements — Jacobo

PR4: Análisis datos combinados pasos 8, 9, 11, 12, 13, tablas y gráficos — Helen

PR5: Documentación conflicto resuelto y cierre del proyecto — Jacobo

PR6: Agregar roles de integrantes en README — Jacobo

Cada Pull Request fue revisado y aprobado por el otro integrante mediante comentarios en GitHub web antes de ser fusionado, evidenciando el proceso de revisión entre compañeros.

4.5 Conflicto de fusión resuelto

Durante el desarrollo del proyecto se generó intencionalmente un conflicto de fusión para practicar la resolución de conflictos en GitHub.

Cómo ocurrió el conflicto

Jacobo editó la sección de Objetivo del archivo README.md en su rama rama/analisis-estadistico-inicial, agregando una descripción enfocada en las habilidades de trabajo colaborativo. Al mismo tiempo, Helen editó la misma sección del mismo archivo en su rama rama/unificacion-datos con una descripción enfocada en las técnicas de análisis estadístico.

Al intentar hacer el merge de la rama de Helen hacia main, GitHub detectó que ambas ramas habían modificado el mismo archivo en la misma sección, generando un conflicto que no pudo resolverse automáticamente.

[INSERTAR AQUÍ CAPTURA DE PANTALLA 1: Pantalla de GitHub Desktop o GitHub web mostrando el mensaje de conflicto]

Cómo se resolvió el conflicto

El conflicto se resolvió desde la Terminal usando los siguientes comandos:

```
git status
```

Luego se eligió mantener la versión propia de cada integrante:

```
git checkout --ours notebooks/proyecto_titanic.ipynb  
git checkout --ours data/README.md
```

Se marcaron los archivos como resueltos:


```
git add notebooks/proyecto_titanic.ipynb  
git add data/README.md
```

Se hizo el commit de la resolución:

```
git commit -m "Resolver conflicto de fusión manteniendo versión propia"
```

Finalmente se subieron los cambios:

```
git push
```



```
taller-pandas-titanic-JacoboyHelenF — zsh — 80x24

Unmerged paths:
  (use "git add <file>..." to mark resolution)
    both modified:   notebooks/proyecto_titanic.ipynb

no changes added to commit (use "git add" and/or "git commit -a")
[jacobobeltran@MacBook-Air-de-Jacobo taller-pandas-titanic-JacoboyHelenF % git checkout --ours notebooks/proyecto_titanic.ipynb
Updated 1 path from the index
[jacobobeltran@MacBook-Air-de-Jacobo taller-pandas-titanic-JacoboyHelenF % git add notebooks/proyecto_titanic.ipynb
[jacobobeltran@MacBook-Air-de-Jacobo taller-pandas-titanic-JacoboyHelenF % git commit -m "Resolver conflicto de fusion en notebook manteniendo version de Jacobo"

[rama/analisis-estadistico-inicial 9746a1c] Resolver conflicto de fusion en notebook manteniendo version de Jacobo
[jacobobeltran@MacBook-Air-de-Jacobo taller-pandas-titanic-JacoboyHelenF % git push
Username for 'https://github.com': JacoboBeltran22
[Password for 'https://Jacobobeltran22@github.com':
remote: Invalid username or token. Password authentication is not supported for Git operations.
fatal: Authentication failed for 'https://github.com/JuanBeltran16/taller-pandas-titanic-JacoboyHelenF.git/'
jacobobeltran@MacBook-Air-de-Jacobo taller-pandas-titanic-JacoboyHelenF %
```

```
Windows PowerShell
Copyright (C) Microsoft Corporation. Todos los derechos reservados.

Instale la versión más reciente de PowerShell para obtener nuevas características y mejoras. https://aka.ms/PSWindows

PS C:\Users\rueda> cd "C:\Users\rueda\AppData\Local\GitHubDesktop\app-3.5.8\taller-pandas-titanic-JacoboyHelenF"
PS C:\Users\rueda\AppData\Local\GitHubDesktop\app-3.5.8\taller-pandas-titanic-JacoboyHelenF> git status
On branch rama/unificacion-datos
Your branch is up to date with 'origin/rama/unificacion-datos'.

nothing to commit, working tree clean
PS C:\Users\rueda\AppData\Local\GitHubDesktop\app-3.5.8\taller-pandas-titanic-JacoboyHelenF> git fetch origin
PS C:\Users\rueda\AppData\Local\GitHubDesktop\app-3.5.8\taller-pandas-titanic-JacoboyHelenF> git merge origin/main
Auto-merging data/README.md
CONFLICT (content): Merge conflict in data/README.md
Auto-merging notebooks/proyecto_titanic.ipynb
CONFLICT (content): Merge conflict in notebooks/proyecto_titanic.ipynb
Automatic merge failed; fix conflicts and then commit the result.
PS C:\Users\rueda\AppData\Local\GitHubDesktop\app-3.5.8\taller-pandas-titanic-JacoboyHelenF> git checkout --ours data/README.md
Updated 1 path from the index
PS C:\Users\rueda\AppData\Local\GitHubDesktop\app-3.5.8\taller-pandas-titanic-JacoboyHelenF> git checkout --ours notebooks/proyecto_titanic.ipynb
Updated 1 path from the index
PS C:\Users\rueda\AppData\Local\GitHubDesktop\app-3.5.8\taller-pandas-titanic-JacoboyHelenF> git add data/README.md notebooks/proyecto_titanic.ipynb
PS C:\Users\rueda\AppData\Local\GitHubDesktop\app-3.5.8\taller-pandas-titanic-JacoboyHelenF> git commit -m "Resolver conflicto de fusion manteniendo version de Helen"
[rama/unificacion-datos a76b45a] Resolver conflicto de fusion manteniendo version de Helen
PS C:\Users\rueda\AppData\Local\GitHubDesktop\app-3.5.8\taller-pandas-titanic-JacoboyHelenF> |
```